

1. Tóm tắt

Bối cảnh

- **Hạn chế của các mô hình đơn hướng:** Các mô hình tiền huấn luyện phổ biến thời điểm đó như OpenAI GPT sử dụng kiến trúc Transformer đơn hướng (trái sang phải). Do mỗi token chỉ được truy cập ngữ cảnh bên trái, mô hình gặp khó khăn trong việc học biểu diễn ngữ nghĩa dựa trên đồng thời cả ngữ cảnh bên trái và bên phải của từ.
- **Khó khăn trong học biểu diễn hai chiều sâu:** ELMo khai thác ngữ cảnh hai chiều bằng cách kết hợp đầu ra của hai mạng LSTM chạy theo hai hướng trái-sang-phải và phải-sang-trái. Tuy nhiên, hai mạng này được huấn luyện độc lập và chỉ được ghép nối ở tầng cuối, khiến mô hình chưa học được các biểu diễn hai chiều sâu, nơi thông tin từ cả hai hướng được tích hợp xuyên suốt trong toàn bộ mạng.


Giải pháp cốt lõi

- Đề xuất mô hình BERT (Bidirectional Encoder Representations from Transformers) – sử dụng Transformer Encoder hai chiều sâu để học các biểu diễn ngôn ngữ. BERT giải quyết hạn chế trên bằng tác vụ tiền huấn luyện Masked Language Model (MLM) và Next Sentence Prediction (NSP).

Mục tiêu

- Xây dựng một mô hình tiền huấn luyện tổng quát có thể được fine-tune dễ dàng cho nhiều tác vụ NLP khác nhau chỉ bằng cách bổ sung một lớp đầu ra đơn giản.

2. Kiến trúc mô hình



BERT được xây dựng từ một chuỗi gồm L lớp Encoder xếp chồng lên nhau ($L = 12$ đối với BERT Base và $L = 24$ đối với BERT Large).

2.1. Cấu trúc đầu vào (Input/Output Representations)




Figure 2: BERT input representation. The input embeddings are the sum of the token embeddings, the segmentation embeddings and the position embeddings.

Vector đầu vào của mỗi từ trong BERT là tổng hợp của 3 loại embeddings độc lập:

- Token Embeddings: Sử dụng thuật toán WordPiece với bộ từ vựng 30,000 token. Cách này giúp phân tách từ hiếm thành các subwords, giảm thiểu vấn đề out-of-vocabulary.
 - [CLS]: Luôn là token đầu tiên của mọi chuỗi. Vector đầu ra của token [CLS] ở tầng encoder cuối cùng thường được sử dụng làm biểu diễn cho toàn bộ chuỗi trong các tác vụ phân loại.
 - [SEP]: Dùng để phân tách các câu trong trường hợp đầu vào là một cặp câu.
- Segment Embeddings: Nhiều bài toán (như QA hay NLI) yêu cầu đầu vào là một cặp câu. Để mô hình phân biệt được đâu là câu A, đâu là câu B, BERT sử dụng 2 vector embeddings: E_A và E_B . Nếu một token thuộc câu A, nó sẽ được cộng thêm E_A , nếu thuộc câu B sẽ được cộng thêm E_B . Điều này cung cấp tín hiệu mạnh mẽ giúp mô hình nhận biết ranh giới của từng câu ngoài việc chỉ dùng token [SEP].
- Learned Position Embeddings: BERT tự học các vector biểu diễn vị trí này trực tiếp từ dữ liệu. Nó hỗ trợ độ dài chuỗi tối đa là 512 token, tương ứng với 512 position vector embedding. Các vector này được khởi tạo ngẫu nhiên và tối ưu hóa qua quá trình huấn luyện.

2.2. Tiền huấn luyện không giám sát (Unsupervised Pre-training)

Task 1: Masked Language Model (MLM)

- Ngẫu nhiên che đi (mask) 15% số token và yêu cầu mô hình dự đoán từ bị che. Hàm loss được tính bằng:

$$\mathcal{L}_{MLM} = - \sum_{i \in M} \log P(x_i | x_{\setminus M}; \theta)$$

M là tập hợp vị trí bị che; x_i là từ gốc tại vị trí i , $x_{\setminus M}$ là ngữ cảnh xung quanh. Trong 15% token được chọn, 80% được thay bằng [MASK], 10% được thay bằng token ngẫu nhiên và 10% được giữ nguyên để giảm sự khác biệt giữa giai đoạn pre-training và fine-tuning.

Task 2: Next Sentence Prediction (NSP)

- Huấn luyện mô hình phân loại nhị phân: Cho câu A và câu B, dự đoán xem B có phải là câu đi liền sau A trong văn bản gốc hay không. Sử dụng vector output C của token [CLS] để tính xác suất:

$$P(y_{NSP} | A, B) = \text{softmax}(CW_{NSP})$$

$$\mathcal{L}_{NSP} = -\log P(y_{NSP} | A, B)$$

C là vector đại diện cho toàn bộ cặp câu; W_{NSP} là ma trận trọng số phân loại nhị phân.

Tổng hàm loss trong giai đoạn tiền huấn luyện là sự kết hợp của cả hai nhiệm vụ trên:

$$\mathcal{L}_{total} = \mathcal{L}_{MLM} + \mathcal{L}_{NSP}$$

2.3. Luồng dữ liệu:

1. **Đầu vào:** Tokenizer WordPiece tách từ và chèn [CLS], [SEP]. Chuỗi đầu vào có N token ($N \leq 512$)
2. **Khởi tạo Vector (Embedding Layer):** Mỗi token chuyển hóa thành vector cơ sở $h^{(0)}$ thuộc R^H thông qua việc cộng 3 loại embedding vector. Ma trận tổng có kích thước $R^{N \times H}$
3. **Xử lý qua các tầng Encoder:** $h^{(0)}$ đi qua L tầng Encoder, liên tục dùng self-attention để nhìn ngữ cảnh hai chiều và cập nhật sinh ra $h^{(l)}$
 - Thay vì dùng hàm kích hoạt ReLU truyền thống, BERT sử dụng GELU (Gaussian Error Linear Unit) ở lớp Feed-Forward. Khác với ReLU cắt bỏ đột ngột các giá trị âm thành 0, GELU cho phép một lượng nhỏ tín hiệu âm đi qua theo phân phối xác suất. Điều này giúp giảm hiện tượng dying ReLU, làm cho quá trình tối ưu hóa bằng Gradient Descent ổn định hơn và mô hình hội tụ nhanh hơn.
4. **Đầu ra cuối cùng:** Ma trận đầu ra thuộc $R^{N \times H}$ chứa vector C (cho token [CLS]) và các vector T_i (cho các từ còn lại), sẵn sàng cắm vào các lớp dự đoán.

2.4. Fine-tuning

Mức câu (Sequence-level) - Vd: Phân loại, Suy luận

- Đầu vào: [CLS] Câu A [SEP] Câu B [SEP]
- Dự đoán: Sau khi đi qua toàn bộ các tầng Transformer Encoder, lấy vector $C \in R^H$ của token [CLS]. Vector C được xem là biểu diễn của toàn bộ chuỗi đầu vào. Để thực hiện phân loại, vector này được đưa qua một lớp tuyến tính với ma trận trọng số: $W \in R^{K \times H}$ (trong đó K là số nhãn phân loại, H là kích thước vector ẩn của BERT). Xác suất dự đoán cho lớp thứ (k) được tính bằng:

$$P(y = k | X) = \text{softmax}(CW^T)_k$$

Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán cuối cùng.

Mức từ (Token-level) - Vd: SQuAD QA

- Đầu vào: [CLS] Câu hỏi [SEP] Đoạn văn [SEP]
- Sau khi qua BERT, mỗi token trong chuỗi nhận được một vector biểu diễn ngữ cảnh: $T_1, T_2, \dots, T_N$
- Dự đoán: Trong bài toán Question Answering, mục tiêu là xác định vị trí bắt đầu (Start) và vị trí kết thúc (End) của câu trả lời trong đoạn văn. Để thực hiện điều này, mô hình học hai vector trọng số: S thuộc R^H và E thuộc R^H tương ứng với bộ phân loại vị trí bắt đầu và vị trí kết thúc. Xác suất từ thứ i là điểm bắt đầu được tính bằng softmax trên toàn chuỗi:

$$P_i^{(start)} = \frac{e^{S \cdot T_i}}{\sum_j e^{S \cdot T_j}}$$

Làm tương tự cho điểm kết thúc, mô hình tìm cặp vị trí $((i, j))$ sao cho $i \leq j$ và $P_i^{(start)} * P_j^{(end)}$ là lớn nhất. Đoạn văn bản từ token (i) đến token (j) sẽ được chọn làm câu trả lời cuối cùng.

3. Thực nghiệm và kết quả

- **GLUE Benchmark:** GLUE (General Language Understanding Evaluation) là bộ tiêu chuẩn đa dạng bao gồm phân loại cảm xúc, đo lường độ tương đồng văn bản, và suy luận hệ quả (NLI). Cho một câu đơn hoặc một cặp câu, bài toán yêu cầu dự đoán chính xác nhãn tương ứng.
Kết quả: BERT-Large đạt trung bình 82.1%, tăng tận 7.0% tuyệt đối so với kỷ lục tốt nhất trước đó (OpenAI GPT). Thể hiện khả năng suy luận, hiểu ngôn ngữ tổng quát rất tốt

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
BERT _{BASE}	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	92.7	94.9	60.5	86.5	89.3	70.1	82.1

- **SQuAD v1.1 & v2.0 (Hỏi đáp):** SQuAD (Stanford Question Answering Dataset) là tập dữ liệu đọc hiểu. Cho trước một câu hỏi và một đoạn văn bản trích từ Wikipedia có chứa câu trả lời, nhiệm vụ của mô hình là dự đoán đoạn văn bản (text span) chứa đáp án chính xác.
Kết quả: Mô hình BERT-Large đánh bại cả điểm số của con người và vượt mặt các cấu trúc Ensemble phức tạp nhất, đạt F1 93.2 (v1.1) và 83.1 (v2.0).

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	-	-	82.3	91.2
#1 Ensemble - nlnet	-	-	86.0	91.7
#2 Ensemble - QANet	-	-	84.5	90.5
Published				
BiDAF+ELMo (Single)	-	85.6	-	85.8
R.M. Reader (Ensemble)	81.2	87.9	82.3	88.5
Ours				
BERT _{BASE} (Single)	80.8	88.5	-	-
BERT _{LARGE} (Single)	84.1	90.9	-	-
BERT _{LARGE} (Ensemble)	85.8	91.8	-	-
BERT _{LARGE} (Sgl.+TriviaQA)	84.2	91.1	85.1	91.8
BERT _{LARGE} (Ens.+TriviaQA)	86.2	92.2	87.4	93.2

Table 2: SQuAD 1.1 results. The BERT ensemble is 7x systems which use different pre-training checkpoints and fine-tuning seeds.

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	86.3	89.0	86.9	89.5
#1 Single - MIR-MRC (F-Net)	-	-	74.8	78.0
#2 Single - nlnet	-	-	74.2	77.1
Published				
unet (Ensemble)	-	-	71.4	74.9
SLQA+ (Single)	-	-	71.4	74.4
Ours				
BERT _{LARGE} (Single)	78.7	81.9	80.0	83.1

Table 3: SQuAD 2.0 results. We exclude entries that use BERT as one of their components.

- **SWAG (Suy luận logic đời thường):** SWAG (Situations With Adversarial Generations) là tập dữ liệu đánh giá khả năng suy luận thường thức (commonsense inference). Cho trước một ngữ cảnh (một câu), mô hình phải chọn ra viễn cảnh/hành động hợp lý nhất sẽ xảy ra tiếp theo trong số 4 lựa chọn có sẵn.
Kết quả: BERT vượt qua OpenAI GPT với khoảng cách 8.3%.

System	Dev	Test
ESIM+GloVe	51.9	52.7
ESIM+ELMo	59.1	59.2
OpenAI GPT	-	78.0
BERT _{BASE}	81.6	-
BERT _{LARGE}	86.6	86.3
Human (expert) [†]	-	85.0
Human (5 annotations) [†]	-	88.0

4. Ablation Study

- **No NSP (Bỏ tác vụ dự đoán câu tiếp theo):** Mô hình vẫn là hai chiều (MLM) nhưng không được huấn luyện phân biệt cặp câu. Kết quả: Khả năng nhận diện quan hệ hệ quả cấp câu (NLI) như MNLI và QNLI giảm sút rõ rệt. Hiệu suất SQuAD cũng giảm.
- **LTR & No NSP (Mô hình Trái-sang-Phải, giống OpenAI GPT):** Mô hình bị tước đi tính năng đọc hai chiều (thay MLM bằng Causal LM truyền thống). Kết quả: Hiệu suất giảm đáng kể trên hầu hết các benchmark được đánh giá. Đặc biệt ở bài toán SQuAD, mô hình gặp khó khăn trong việc xác định chính xác vị trí câu trả lời do không khai thác được ngữ cảnh bên phải.
- Nhóm nghiên cứu đã thử nghiệm nhiều biến thể: số tầng (L), kích thước ẩn (H), và số luồng chú ý (A).

⇒ Kết luận: "Mô hình càng to, biểu diễn ngôn ngữ học được càng vững". Việc tăng từ BERT-Base (110M tham số) lên BERT-Large (340M tham số) mang lại sự cải thiện nhất quán trên toàn bộ các tác vụ. Đặc biệt, nó chứng minh rằng việc tăng quy mô mô hình vẫn cực kỳ hiệu quả ngay cả khi tập dữ liệu Fine-tuning cực nhỏ (như MRPC chỉ có 3.600 mẫu), miễn là mô hình đã được Pre-training đủ tốt.

5. Kết luận

Bằng cách kết hợp kiến trúc Transformer hai chiều với các nhiệm vụ tiền huấn luyện MLM và NSP, BERT đã tạo ra một mô hình biểu diễn ngôn ngữ tổng quát có khả năng thích ứng hiệu quả với nhiều tác vụ NLP khác nhau thông qua fine-tuning đơn giản. Kết quả thực nghiệm cho thấy BERT đạt hiệu năng vượt trội trên nhiều benchmark tiêu chuẩn và trở thành nền tảng cho nhiều nghiên cứu NLP sau này.